


Analysez l'évolution du profil sociodémographique des étudiants Data d'OpenClassrooms




Pierre-Antoine Morin
Data Analyst – Projet 8
11/04/2026



Contexte et mission du projet

- OpenClassrooms : école des métiers du digital 100% en ligne
 - 600 cours en accès libre et gratuit
 - 50 parcours de formation débouchant sur des métiers d'avenir (certification/titre RNCP)
 - Plus de 3 millions d'apprenants chaque mois à travers le monde




- Analyse rétrospective du profil socio-démographique des étudiants du parcours Data Analyst
 - Transformation fiable, documentée, reproductible
 - Qualité des données + Respect du RGPD + Enrichissement/Contextualisation

Données : sources, stockage, transformation

- Données internes OpenClassrooms
 - Fichier CSV, format tabulaire (données en ligne + entêtes)
- Données publiques INSEE
 - Estimation de population par région, sexe et âge quinquennal de 1975 à 2025
<https://www.insee.fr/fr/statistiques/8331297>
 - Fichier Excel, 1 feuille par année (lignes = régions, colonnes = genre + tranche d'âge)
- Technologies utilisées
 - **MS Excel** : formatage des données INSEE + création des graphiques
 - **Snowflake** = entrepôt de données en ligne : stockage + puissance de calcul
 - **DBT Cloud** = IDE en ligne : orchestrateur des calculs + documentation

Processus de transformation des données



Outils cloud : connexion et sécurité

 Nom d'utilisateur
 Mot de passe
 TOTP




 Clé RSA publique

 Nom d'utilisateur
 Mot de passe
 TOTP



 Clé RSA privée



Pipeline de données en 4 couches

1. Données brutes

- **Snowflake** : importation des 2 fichiers CSV (raw)
- **DBT** : 2 fichiers CSV auxiliaires (seeds/sed) pour les correspondances
 - Régions : orthographe (Centre-Val de Loire), granularité (DROM)
 - Tranches d'âge : format, granularité (au-delà de 60 ans)

2. Staging (stg) = nettoyage des données


- OpenClassrooms : Genre manquant → Valeur « Non renseigné »
- INSEE : Suppression des tranches d'âge en-deçà de 20 ans

3. Intermediate (int) = calcul des effectifs


- OpenClassrooms : disparition des identifiants (RGPD)
- INSEE : agrégation selon la granularité OpenClassrooms

4. Mart (mrt) final = regroupement des données

- **Snowflake** : exportation au format CSV



Graphe d'antériorité des modèles DBT




Qualité et reproductibilité du pipeline

- Tests basiques
 - `not_null` (absence de valeurs manquantes)
 - `unique` (vérification de l'unicité pour les identifiants)
 - `accepted_values` (variables restreintes : genre, région, tranche d'âge)
- Tests avancés : package `dbt_utils`
 - `unique_combination_of_columns` (effectifs regroupés une seule fois)
 - `accepted_range` (un effectif ne peut pas être négatif)
- Tests personnalisés
 - `test_stg_students` : Certains étudiants apparaissent plusieurs fois, mais jamais plus d'une fois par an, toujours avec le même genre et la même tranche d'âge.
 - `test_mrt_insee_students` (effectifs INSEE nuls lorsque le genre est non renseigné)


Tous les modèles sont testés et documentés.

Parmi les étudiants Data d'OpenClassrooms, les hommes sont sur-représentés.


Évolution du nombre d'étudiants détaillé par genre




Évolution de la répartition des genres parmi les étudiants



La sous-représentation des femmes concerne toutes les classes d'âge.



Parmi les étudiants Data d'OpenClassrooms, certaines régions sont sur/sous-représentées.



Conclusions et perspectives

- Le nombre d'étudiants Data baisse de 2022 à 2024 mais augmente en 2025.
- Les femmes sont sous-représentées parmi les étudiants Data.
Ce phénomène se produit tous les ans, toutes les tranches d'âge sont affectées.
- Les régions sont représentées de manière inégale parmi les étudiants Data.
 - La majorité des étudiants est originaire de la région Île-de-France.
 - Les régions Provence-Alpes-Côte d'Azur et Centre-Val de Loire sont sur-représentées.
 - La région Nouvelle Aquitaine est sous-représentée.
- Pistes d'amélioration du processus de transformation des données en vue d'une exécution automatisée et répétée
 - Réduire le nombre d'outils : ne plus utiliser **Power Query (MS Excel)**
 - **Snowflake** : données INSEE brutes, visualisations graphiques des marts
 - **DBT** : [dé]pivotage (SQL), paramétrisation des années (Jinja)