

Pilotez un projet data
augmenté avec l'IA

Créez votre portfolio
de professionnel

Pierre-Antoine Morin

OpenClassrooms – Data Analyst – Projet 13

Plan de la présentation

1. Pilotez un projet data augmenté avec l'IA
 - Introduction et contexte
 - Veille technologique : méthodologie, synthèse
 - Mise en œuvre : Polars, Pingouin
 - Résultats, limites, perspectives
2. Créez votre portfolio de professionnel
 - Réalisation du portfolio
 - Conclusion

Pilotez un projet data augmenté avec l'IA

Mission 1

Introduction & Contexte



- Reprise du projet 6
Optimisez la gestion des données d'une boutique
- Client : marchand de vins haut de gamme
- Données difficiles à exploiter
 - Identifiant produit différent entre l'ERP et le site web → Table de liaison
 - Schéma relationnel (ex : colonnes redondantes ~~troisième forme normale~~)
 - Incohérences intra-colonne (ex : valeurs négatives de prix, stock, ventes)
 - Incohérences inter-colonnes (ex : prix de vente < prix fournisseur)
- Analyse des ventes sur un mois
 - Analyses univariées, corrélations

Amélioration avec l'IA

Objectif : Utiliser l'IA de manière critique et documentée

Amélioration continue + Démarche reproductible

1. Veille technologique : identifier les outils pertinents
2. Assistant de code : amélioration du notebook Jupyter (Python)
3. Gestion de projet : cahier des charges, formation métier

Veille technologique : méthodologie

Utilisation du même prompt envoyé à 2 agents IA

1. ChatGPT (Open AI)

- Moteur IA très performant, largement répandu
- Modèle propriétaire, USA



2. Vibe (Mistral AI)

- Moteur IA performant, moins connu
- Open source (partiel), France (respect du RGPD)



Veille technologique : synthèse

Axe d'amélioration	Outil	Pertinence dans le cadre du projet
Qualité du nettoyage	Pandera	Validation des règles métier dans les DataFrames
	Great Expectations	Qualité documentée et industrialisée
Accélérer l'analyse exploratoire	Polars	DataFrames performants
	DuckDB	SQL analytique local
Interprétabilité	Pingouin	Tests statistiques via une interface simplifiée
	SHAP	Explication de modèles ML prédictifs
Déploiement Reproductibilité	Prefect	Orchestration des workflows de données en Python
	dbt	SQL data pipelines avec tests et documentation

Analyse exploratoire optimisée avec Polars

- Polars : *"DataFrames for the new era"*
 - Très rapide (Rust, parallélisation)
 - Typage de colonne strict (données structurées)
 - Plusieurs modes d'évaluation
 - Eager (glouton) : exécution immédiate (interactif : adapté pour notebook)
 - Lazy (paresseux) : exécution différée (chaîne de traitement optimisée)
 - Capable d'agréger des données sans tout charger en mémoire
- Mise en œuvre
 - Remplacement complet de Pandas par Polars : import/EDA/export
 - Conversion Polars → Pandas avant l'analyse statistique (meilleure intégration)



Analyse statistique approfondie avec Pingouin

- Pingouin : *"Simple yet exhaustive stats functions"*
 - Interface intuitive : fonctions adaptées aux tests statistiques courants
 - Résultats complets : valeur du test statistique, p-value, taille d'effet, ...
- Mise en œuvre
 - Définition de 4 fonctions de tests statistiques
 1. Variable quantitative VS Variable quantitative
 2. Variable qualitative VS Variable qualitative
 3. Variable quantitative VS Variable binaire (qualitative, 2 valeurs)
 4. Variable quantitative VS Variable qualitative avec au moins 3 valeurs
 - Test de normalité intégré, choix automatique (test paramétrique ou non)
 - Application aux données



Résultats, limites, perspectives

- Résultats

- Améliorations fonctionnelles du notebook
- Confirmation des tendances grâce aux tests statistiques

- Limites

- Volume de données faible (jointure finale : moins de 1000 lignes)
- Pas d'accélération perceptible de l'EDA
- Tests statistiques quali/quali non applicables (effectifs trop petits)

- Perspectives

- Tester sur de plus gros volumes de données
- Ajouter les dates de transaction → Analyse prédictive

Créez votre portfolio de professionnel

Mission 2

Réalisation du portfolio

<https://github.com/ppa-go-git-hub/data-analyst-portfolio>

- Accueil (README principal)
 - Stack technique
 - Compétences clés
 - Liste détaillée des compétences acquises dans chaque projet
- Un sous-dossier par projet de la formation Data Analyst
 - Présentation du contexte (README dédié)
 - Livrables techniques, supports de présentation, documentation

Conclusion

- Projet final : prise de recul sur le parcours de formation
- Démarche d'amélioration continue
- Pilotage de projet et documentation
- Usage critique de l'IA
- Portfolio : mise en valeur des compétences acquises

Pilotez un projet data
augmenté avec l'IA

Créez votre portfolio
de professionnel

Pierre-Antoine Morin

OpenClassrooms – Data Analyst – Projet 13